



Curso de Assimilação de Dados para Previsão Numérica de Tempo e Clima



Curso de Assimilação de Dados Atmosféricos

Carga horária sugerida: 40–60 horas

Formato: Aulas teóricas + exercícios práticos (Python/Fortran) + estudo de casos reais



Módulo 2 — Formulação matemática

1.Representação do estado

1. Vetor de estado x
2. Equações de evolução:

$$x_k = M_{k-1}(x_{k-1}) + \eta$$

1.Observações

1. Operador de observação H
2. Relação com o estado:

$$y_k = H_k(x_k) + \epsilon$$

1.Tipos de erros

1. Matriz de covariância de erro de background (B)
2. Matriz de covariância de erro de observação (R)

2.Função custo

1. Forma geral 3D-Var:

$$J(x) = (x - x_b)^T B^{-1} (x - x_b) + (y - Hx)^T R^{-1} (y - Hx)$$



Módulo 2 — Formulação Matemática



Módulo 2 — Formulação Matemática

1. Representação do Estado

O estado do sistema é a descrição matemática das condições da atmosfera em um dado momento.

O vetor $\vec{x}$ representa esse estado da condições da atmosfera em um dado momento, que contém variáveis como temperatura, umidade, pressão e vento em diversos pontos de uma grade tridimensional.

O objetivo da assimilação de dados é ajustar esse vetor $\vec{x}$ para que ele se aproxime o mais possível das observações reais y .

1.1 Definição do Vetor de Estado

O vetor de estado $\vec{x}$ pode ser representado como uma combinação de variáveis físicas na grade do modelo:

$$x = [T_1 \quad T_2 \quad T_3 \quad \dots \quad T_n]^T$$

onde T_i é a variável física no ponto i da grade (por exemplo, temperatura).

Assim, $\vec{x}$ pode ser um vetor de temperatura, umidade, ou uma combinação dessas variáveis.



Módulo 2 — Formulação Matemática

1. Representação do Estado

1.2 Equações de Evolução

A equação de evolução do estado é dada pela equação de previsão:

$$x_k = M_{k-1}(x_{k-1}) + \eta$$

onde:

- x_k é o vetor de estado no passo k ,
- M_{k-1} é o operador do modelo (pode ser uma equação diferencial),
- η é o erro ou ruído no modelo, que representa incertezas do modelo.



Módulo 2 — Formulação Matemática

2. Observações

As **observações** do sistema, **definida por y** , são feitas em pontos específicos da grade ou em variáveis específicas (como a temperatura na superfície, ou umidade em uma estação).

2.1 Operador de Observação (H)

O **operador de observação H** mapeia o vetor de estado para as observações. Ele pode ser linear ou não linear, dependendo do tipo de dados observados. Em um modelo simples, temos:

$$y_k = H_k(x_k) + \epsilon$$

onde:

y_k é o vetor de observações no passo k ,
 $H_k(x_k)$ é a previsão do modelo para as observações,
 ϵ é o erro ou ruído da observação, que representa incertezas nos dados.

2.2 Erro de Observação (R)

A matriz **R** é a matriz de covariância do erro de observação. Ela descreve a incerteza ϵ associada a cada observação e é crucial para o ajuste do modelo.



Módulo 2 — Formulação Matemática

3. Função Custo

A **função custo** é uma medida da discrepância entre o estado do modelo e as observações. O objetivo da assimilação de dados é minimizar essa função para obter o melhor estado possível do sistema.

3.1 Função Custo para 3D-Var

A forma clássica da função custo no método **3D-Var** é dada por:

$$J(x) = (x - x_b)^T B^{-1} (x - x_b) + (y - Hx)^T R^{-1} (y - Hx)$$

onde:

x_b é o estado de fundo (modelo),

B é a matriz de covariância do erro de fundo (modelo),

y são as observações,

H é o operador de observação,

R é a matriz de covariância do erro da observação.



Módulo 2 — Formulação Matemática

3. Função Custo

$$J(x) = (x - x_b)^T B^{-1} (x - x_b) + (y - Hx)^T R^{-1} (y - Hx)$$

3.2 Significado dos Termos

- O primeiro termo $(x - x_b)^T B^{-1} (x - x_b)$ mede a **discrepância entre** o **estado do modelo** e o **estado de fundo**, ajustado pelas incertezas do modelo.
- O segundo termo $(y - Hx)^T R^{-1} (y - Hx)$ mede a **discrepância entre** as **observações** e as **previsões do modelo**, **ajustadas pelas incertezas H das observações**.



Módulo 2 — Formulação Matemática

4. Método de Mínimos Quadrados

Uma maneira de minimizar a função custo é através de um **método de mínimos quadrados**.

O objetivo é encontrar o valor de x que minimiza a função $J(x)$.



Módulo 2 — Formulação Matemática

4.1 Derivação e Solução

A solução para o problema de otimização é dada por:

$$\hat{x} = x_b + BH^T (HBH^T + R)^{-1} (y - Hx_b)$$

onde:

- $\hat{x}$ é o estado corrigido após a assimilação,
- B é a matriz de covariância do erro do modelo,
- H é o operador de observação,
- R é a matriz de covariância do erro da observação.

Esta fórmula mostra como o estado x do modelo é ajustado pelas observações y , ponderado pelas incertezas no modelo (B) e das observações (R).



2) Gradiente de $J(x)$

Calcule a derivada de $J(x)$ em relação a x . Usando regras de derivação matricial (e lembrando que $\nabla_x(x^T A x) = (A + A^T)x$; aqui B^{-1} e R^{-1} são simétricos:

Para o primeiro termo:

$$\nabla_x[(x - x_b)^T B^{-1}(x - x_b)] = [(1)^T B^{-1}(x - x_b) + (x - x_b)^T B^{-1}(1)] = 2B^{-1}(x - x_b)$$

$$\nabla_x[(x - x_b)^T B^{-1}(x - x_b)] = [B^{-1}(\mathbf{x} - \mathbf{x}_b) + B^{-1}(\mathbf{x} - \mathbf{x}_b)^T] = 2B^{-1}(\mathbf{x} - \mathbf{x}_b)$$

Para o segundo termo (note $\mathbf{y} - \mathbf{H}\mathbf{x}$):

$$\nabla_x[(\mathbf{y} - \mathbf{H}\mathbf{x})^T R^{-1}(\mathbf{y} - \mathbf{H}\mathbf{x})] = [(-\mathbf{H})^T R^{-1}(\mathbf{y} - \mathbf{H}\mathbf{x}) + (\mathbf{y} - \mathbf{H}\mathbf{x})^T R^{-1}(-\mathbf{H})] = 2\mathbf{H}^T R^{-1}(\mathbf{y} - \mathbf{H}\mathbf{x})$$

$$\nabla_x[(\mathbf{y} - \mathbf{H}\mathbf{x})^T R^{-1}(\mathbf{y} - \mathbf{H}\mathbf{x})] = [-(\mathbf{H})^T R^{-1}(\mathbf{y} - \mathbf{H}\mathbf{x}) - (\mathbf{H})R^{-1}(\mathbf{y} - \mathbf{H}\mathbf{x})^T] = 2\mathbf{H}^T R^{-1}(\mathbf{y} - \mathbf{H}\mathbf{x})$$

Somando:

$$\nabla_x J(x) = 2[B^{-1}(x - x_b) - H^T R^{-1}(y - Hx)]$$



3) Condição de ótimo (gradiente zero)

$$\nabla_x J(x) = 0$$

$$2[B^{-1}(x - x_b) - H^T R^{-1}(y - Hx)] = 0$$

$$[B^{-1}(x - x_b) - H^T R^{-1}(y - Hx)] = 0$$

Rearranjando:

$$[(B^{-1}x - B^{-1}x_b) - (H^T R^{-1}y - H^T R^{-1}Hx)] = 0$$

$$B^{-1}x - B^{-1}x_b - H^T R^{-1}y + H^T R^{-1}Hx = 0$$

Agrupando termos em x :

$$B^{-1}x + H^T R^{-1}Hx = B^{-1}x_b + H^T R^{-1}y$$

$$(B^{-1} + H^T R^{-1}H)x = B^{-1}x_b + H^T R^{-1}y$$

Essa é a **equação normal** do problema. A matriz do lado esquerdo é simétrica definida positiva (soma de SPD), logo a solução é única.



4) Solução explícita (forma direta)

$$(B^{-1} + H^T R^{-1} H)x = B^{-1}x_b + H^T R^{-1}y$$

$$(B^{-1} + H^T R^{-1} H)x = (B^{-1}x_b + H^T R^{-1}y)$$

$$x = (B^{-1} + H^T R^{-1} H)^{-1}(B^{-1}x_b + H^T R^{-1}y)$$

Uma forma equivalente, mais usada em assimilação (forma do ganho — “análise incremental”):

Objetivo

Mostrar que

$$x_a = (B^{-1} + H^T R^{-1} H)^{-1}(B^{-1}x_b + H^T R^{-1}y)$$

é equivalente a

$$x_a = x_b + BH^T (HBH^T + R)^{-1}(y - Hx_b).$$

Defina $S = HBH^T + R$ (matriz de inovação) — é invertível se R e B forem SPD.



Passo 1 — identidade de Woodbury

A identidade de Woodbury (forma útil aqui) é, para matrizes conformes:

$$(A + UCV)^{-1} = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}$$

Escolha

$$A = B^{-1}; U = H^T; C = R^{-1}; V = H$$

Então

$$A + UCV = B^{-1} + H^T R^{-1} H$$

Note que usamos

$$(C^{-1} + VA^{-1}U)^{-1} = (R + HBH^T)^{-1} \quad e \quad A^{-1} = B$$

e a identidade dá

$$(B^{-1} + H^T R^{-1} H)^{-1} = B - BH^T(R + H^T BH)^{-1}HB$$



Passo 1 — identidade de Woodbury

$$(B^{-1} + H^T R^{-1} H)^{-1} = B - BH^T (R + H^T B H)^{-1} H B$$

Chamando (a Matriz inovação)

$$S = H B H^T + R$$

podemos escrever que:

$$M \equiv (B^{-1} + H^T R^{-1} H)^{-1} = B - BH^T (S)^{-1} H B$$



Passo 2 — multiplique M por os termos da rhs

Queremos aplicar M ao vetor $B^{-1}x_b + H^T R^{-1}y$. **Use linearidade $f(x_a) = w_1 x_b + w_2 y$:**

$$X_a = B^{-1}x_b + H^T R^{-1}y$$

$$MX_a = MB^{-1}x_b + MH^T R^{-1}y$$

$$x_a = MX_a = M(B^{-1}x_b) + M(H^T R^{-1}y)$$

$$x_a = M(B^{-1}x_b) + M(H^T R^{-1}y)$$

Usando (1):

Termo A: $MB^{-1}x_b$

Termo B: $MH^T R^{-1}y$



Passo 2 — multiplique M por os termos da rhs

$$x_a = M(B^{-1}x_b) + M(H^T R^{-1}y)$$

Calcule cada termo usando (1).

Termo A: $MB^{-1}x_b$ Usando (1):

$$M \equiv (B^{-1} + H^T R^{-1}H)^{-1} = B - BH^T(S)^{-1}HB$$

$$MB^{-1} = (B - BH^T(S)^{-1}HB)B^{-1} = (BB^{-1} - BH^T(S)^{-1}HBB^{-1})$$

$$MB^{-1} = (I - BH^T(S)^{-1}HI)$$

$$MB^{-1} = (1 - BH^T(S)^{-1}H)$$

$$MB^{-1}x_b = (1 - BH^T(S)^{-1}H)x_b$$

$$MB^{-1}x_b = x_b - (BH^T(S)^{-1}H)x_b$$



Passo 2 — multiplique M por os termos da rhs

$$x_a = M(B^{-1}x_b) + M(H^T R^{-1}y)$$

Calcule cada termo usando (1).

Termo B: $MH^T B^{-1}y$

Usando (1) novamente:

$$MH^T R^{-1} = (B - BH^T S^{-1}HB)H^T R^{-1}$$

$$MH^T R^{-1} = (B - BS^{-1}HBH^T)H^T R^{-1}$$

$$MH^T R^{-1} = (B - BS^{-1}(S - R))H^T R^{-1}$$

Reorganize observando que $HBH^T = S - R$

$$MH^T R^{-1} = (B - BS^{-1}S + BS^{-1}R)H^T R^{-1}$$

$$MH^T R^{-1} = (B - B + BS^{-1}R)H^T R^{-1}$$

$$MH^T R^{-1} = (BS^{-1}RR^{-1})H^T$$

$$MH^T R^{-1} = (BH^T S^{-1})$$

$$MH^T R^{-1}y = (BH^T S^{-1})y$$



Passo 2 — multiplique M por os termos da rhs

$$x_a = M(B^{-1}x_b) + M(H^T R^{-1}y)$$

Calcule cada termo usando (1).

Termo B: $MH^T B^{-1}y$

Usando (1) novamente:

$$MH^T R^{-1} = (B - BH^T S^{-1}HB)H^T R^{-1}$$

$$MH^T R^{-1} = (B - BS^{-1}HBH^T)H^T R^{-1}$$

$$MH^T R^{-1} = (B - BS^{-1}(S - R))H^T R^{-1}$$

Reorganize observando que $HBH^T = S - R$

$$MH^T R^{-1} = (B - BS^{-1}S + BS^{-1}R)H^T R^{-1}$$

$$MH^T R^{-1} = (B - B + BS^{-1}R)H^T R^{-1}$$

$$MH^T R^{-1} = (BS^{-1}RR^{-1})H^T$$

$$MH^T R^{-1} = (BH^T S^{-1})$$

$$MH^T R^{-1}y = (BH^T S^{-1})y$$



Passo 3 — somar Termo A $=MB^{-1}x_b = x_b - (BH^T(S)^{-1}H)x_b$ **+ Termo B** $=MH^T R^{-1}y = (BH^T S^{-1})y$

$$x_a = M(B^{-1}x_b) + M(H^T R^{-1}y)$$

$$x_a = x_b - (BH^T(S)^{-1})Hx_b + (BH^T S^{-1})y$$

Agrupar

$$x_a = x_b + (BH^T S^{-1})[-Hx_b + y]$$

$$S = HBH^T + R$$

$$x_a = x_b + (HBH^T + R)^{-1}BH^T[y - Hx_b]$$

E esta é exatamente a **forma do ganho**:

$$x_a = x_b + BH^T(HBH^T + R)^{-1}[y - Hx_b]$$

como queríamos demonstrar.



$$M \equiv (B^{-1} + H^T R^{-1} H)^{-1} = \textcolor{red}{B} - \textcolor{red}{B} H^T (S)^{-1} H B$$

Observação (verificação da identidade $MH^T R^{-1} = BH^T S^{-1}$)

Para quem quiser ver esse passo em detalhe, multiplique:

$$\textcolor{red}{M} H^T R^{-1} \stackrel{(1)}{=} (\textcolor{red}{B} - \textcolor{red}{B} H^T S^{-1} H B) H^T R^{-1}.$$

$$M H^T R^{-1} \stackrel{(1)}{=} B H^T R^{-1} - B H^T S^{-1} H B H^T R^{-1}.$$

$$M H^T R^{-1} \stackrel{(1)}{=} B H^T R^{-1} [1 - S^{-1} \textcolor{teal}{H} B H^T].$$

Agora note que $S = H B H^T + R \Rightarrow R = S - \textcolor{teal}{H} B H^T \Rightarrow \textcolor{teal}{H} B H^T = S - R$.

$$M H^T R^{-1} \stackrel{(1)}{=} B H^T R^{-1} [1 - S^{-1} \textcolor{teal}{H} B H^T].$$

$$M H^T R^{-1} \stackrel{(1)}{=} B H^T R^{-1} [1 - S^{-1} (S - R)].$$

$$M H^T R^{-1} \stackrel{(1)}{=} B H^T R^{-1} [1 - S^{-1} S + S^{-1} R].$$

$$M H^T R^{-1} \stackrel{(1)}{=} B H^T R^{-1} [1 - 1 + S^{-1} R].$$

$$M H^T R^{-1} \stackrel{(1)}{=} B H^T R^{-1} [S^{-1} R].$$

$$M H^T R^{-1} \stackrel{(1)}{=} B H^T R^{-1} R [S^{-1}].$$

$$M H^T R^{-1} \stackrel{(1)}{=} B H^T [S^{-1}].$$

$$M H^T R^{-1} \stackrel{(1)}{=} B H^T S^{-1}$$



$$M \equiv (B^{-1} + H^T R^{-1} H)^{-1} = \textcolor{red}{B} - \textcolor{red}{B} H^T (S)^{-1} H \textcolor{red}{B}$$

Observação (verificação da identidade $MH^T R^{-1} = BH^T S^{-1}$)

$$(BH^T S^{-1})S = BH^T.$$

E comparando com a expressão acima e reordenando termos (uso de $S = HBH^T + R$ (chega-se à igualdade.

Em outras palavras, ambos os lados são soluções da mesma equação linear e, por identidade de Woodbury, são iguais.

(A demonstração formal passa por manipular e cancelar os mesmos termos BH^T e $BH^T S^{-1}HBH^T$).



$$M \equiv (B^{-1} + H^T R^{-1} H)^{-1} = \textcolor{red}{B} - \textcolor{red}{B} H^T (S)^{-1} H B$$

Verificação simbólica com SymPy (equivalência algébrica)

```
import sympy as sp
```

```
# Definir dimensões genéricas
```

```
n, m = sp.symbols('n m', integer=True, positive=True)
```

```
# Definir matrizes simbólicas
```

```
B = sp.MatrixSymbol('B', n, n)
```

```
R = sp.MatrixSymbol('R', m, m)
```

```
H = sp.MatrixSymbol('H', m, n)
```

```
xb = sp.MatrixSymbol('x_b', n, 1)
```

```
y = sp.MatrixSymbol('y', m, 1)
```

```
# Expressões simbólicas
```

```
B_inv = sp.Inverse(B)
```

```
R_inv = sp.Inverse(R)
```

```
# Forma 1 (normal)
```

```
xa1 = sp.Inverse(B_inv + H.T * R_inv * H) * (B_inv * xb + H.T * R_inv * y)
```

```
# Forma 2 (ganho)
```

```
xa2 = xb + B * H.T * sp.Inverse(H * B * H.T + R) * (y - H * xb)
```

```
# Simplificar diferença
```

```
diff = sp.simplify(xa1 - xa2)
```

```
sp.pretty_print(diff)
```

Objetivo

Mostrar que

$$x_a = (B^{-1} + H^T R^{-1} H)^{-1} (B^{-1} x_b + H^T R^{-1} y)$$

é equivalente a

$$x_a = x_b + B H^T (H B H^T + R)^{-1} (y - H x_b).$$

Defina $S = H B H^T + R$ (matriz de inovação) — é invertível se R e B forem SPD.

Matrix([[0], [0], ..., [0]])



$$M \equiv (B^{-1} + H^T R^{-1} H)^{-1} = B - BH^T(S)^{-1}HB$$

Vamos usar números concretos (dimensões pequenas) e calcular x_a pelas **duas fórmulas**.

```
import numpy as np

# Dados exemplo
B = np.array([[1.0, 0.2], [0.2, 2.0]])
R = np.array([[0.5]])
H = np.array([[1.0, 0.0]])
xb = np.array([[10.0], [12.0]])
y = np.array([[11.0]])

# --- Forma 1 (normal) ---
B_inv = np.linalg.inv(B)
R_inv = np.linalg.inv(R)
A = B_inv + H.T @ R_inv @ H
rhs = B_inv @ xb + H.T @ R_inv @ y
xa1 = np.linalg.solve(A, rhs)

# --- Forma 2 (ganho) ---
S = H @ B @ H.T + R
K = B @ H.T @ np.linalg.inv(S)
xa2 = xb + K @ (y - H @ xb)

# --- Comparação ---
print("xa (forma normal):\n", xa1)
print("xa (forma ganho):\n", xa2)
print("Diferença:", np.max(np.abs(xa1 - xa2)))
```

Objetivo

Mostrar que

$$x_a = \overset{A}{(B^{-1} + H^T R^{-1} H)^{-1}} (B^{-1} x_b + H^T R^{-1} y)$$

é equivalente a

$$x_a = x_b + \overset{K}{BH^T (HBH^T + R)^{-1}} (y - Hx_b).$$

Defina $S = HBH^T + R$ (matriz de inovação) — é invertível se R e B forem SPD.

```
xa (forma normal):
[[10.6667]
 [12.1333]]
xa (forma ganho):
[[10.6667]
 [12.1333]]
Diferença: ~1e-15
```



Vamos usar números concretos (dimensões pequenas) e calcular x_a pelas **duas fórmulas**.

```
program var3d_equivalence
  implicit none
  integer, parameter :: n = 2, m = 1
  real :: B(n,n) , R(m,m) , H(m,n), xb(n), y(m)
  real :: Binv(n,n), Rinv(m,m), A(n,n) , rhs(n)
  real :: xa1(n) , xa2(n) , S(m,m), K(n,m)
  integer :: i, j
  ! Dados
  B = reshape([1.0, 0.2, 0.2, 2.0], [n,n])
  R = reshape([0.5], [m,m])
  H = reshape([1.0, 0.0], [m,n])
  xb = [10.0, 12.0]
  y = [11.0]

  ! Inversas (2x2 e 1x1 simples)
  Binv(1,1) = B(2,2)/(B(1,1)*B(2,2)-B(1,2)*B(2,1))
  Binv(2,2) = B(1,1)/(B(1,1)*B(2,2)-B(1,2)*B(2,1))
  Binv(1,2) = -B(1,2)/(B(1,1)*B(2,2)-B(1,2)*B(2,1))
  Binv(2,1) = Binv(1,2)
  Rinv(1,1) = 1.0/R(1,1)

  ! ---- Forma 1 ----
  A = Binv + matmul(transpose(H), matmul(Rinv, H))
  rhs = matmul(Binv, xb) + matmul(transpose(H), matmul(Rinv, y))
  xa1 = matmul(inverse(A), rhs)

  ! ---- Forma 2 ----
  S = matmul(H, matmul(B, transpose(H))) + R
  K = matmul(B, matmul(transpose(H), inverse(S)))
  xa2 = xb + matmul(K, (y - matmul(H, xb)))

  print *, "xa1 (normal): ", xa1
  print *, "xa2 (ganho): ", xa2
  print *, "Diferença: ", maxval(abs(xa1 - xa2))
end program var3d_equivalence
```

Use `contains + função inverse()` de matriz pequena (ou biblioteca LAPACK `dgesv` para versão geral).

Resultado: diferença numérica $\sim 1e-15$.

Forma	Expressão	Observação
Normal	$x_a = (B^{-1} + H^T R^{-1} H)^{-1} (B^{-1} x_b + H^T R^{-1} y)$	Operações no espaço de estado
Ganho (prática)	$x_a = x_b + B H^T (H B H^T + R)^{-1} (y - H x_b)$	Operações no espaço de observação , mais eficiente

Ambas são matematicamente equivalentes — o **script simbólico confirma** a identidade e o **exemplo numérico** mostra que, mesmo com arredondamento, as duas produzem o **mesmo resultado**.



Vamos usar números concretos (dimensões pequenas) e calcular x_a pelas **duas fórmulas**.

```
program var3d_equivalencia
  implicit none
  real(8), dimension(3) :: xb, xa1, xa2, y
  real(8), dimension(3,3) :: B, Binv, Ht, I
  real(8), dimension(1,3) :: H
  real(8), dimension(1,1) :: R, tmp1, tmp2
  integer :: i

  xb = (/10.0d0, 12.0d0, 14.0d0/)
  y = (/13.0d0/)

  B = 0.0d0
  do i=1,3
    B(i,i) = 1.0d0
  end do

  H = reshape([0.0d0, 1.0d0, 0.0d0], shape(H))
  Ht = transpose(H)
  R(1,1) = 0.5d0

  ! Binv = inv(B) (como B = I, é igual)
  Binv = B
  I = B

  ! --- Forma 1 (Kalman gain) ---
  tmp1 = matmul(H, matmul(B, Ht)) + R
  xa1 = xb + matmul(matmul(B, Ht), matmul(inv1x1(tmp1), (y - matmul(H, xb))))

  ! --- Forma 2 (minimização direta) ---
  xa2 = matmul(inv3x3(Binv + matmul(Ht, matmul(inv1x1(R), H))), &
    matmul(Binv, xb) + matmul(Ht, matmul(inv1x1(R), y)))

  print *, 'xa (forma Kalman):', xa1
  print *, 'xa (forma minimização):', xa2
  print *, 'diferença:', xa1 - xa2

contains
```

```
function inv1x1(a) result(ainv)
  real(8), dimension(1,1), intent(in) :: a
  real(8), dimension(1,1) :: ainv
  ainv(1,1) = 1.0d0 / a(1,1)
end function inv1x1

function inv3x3(a) result(ainv)
  real(8), dimension(3,3), intent(in) :: a
  real(8), dimension(3,3) :: ainv
  real(8) :: det
  det = a(1,1)*(a(2,2)*a(3,3)-a(2,3)*a(3,2)) - a(1,2)*(a(2,1)*a(3,3)-a(2,3)*a(3,1)) + a(1,3)*(a(2,1)*a(3,2)-a(2,2)*a(3,1))
  ainv = transpose(reshape([ &
    (a(2,2)*a(3,3)-a(2,3)*a(3,2)), -(a(1,2)*a(3,3)-a(1,3)*a(3,2)), (a(1,2)*a(2,3)-a(1,3)*a(2,2)), &
    -(a(2,1)*a(3,3)-a(2,3)*a(3,1)), (a(1,1)*a(3,3)-a(1,3)*a(3,1)), -(a(1,1)*a(2,3)-a(1,3)*a(2,1)), &
    (a(2,1)*a(3,2)-a(2,2)*a(3,1)), -(a(1,1)*a(3,2)-a(1,2)*a(3,1)), (a(1,1)*a(2,2)-a(1,2)*a(2,1))], [3,3])) / det
end function inv3x3

end program var3d_equivalencia
```

Forma	Expressão	Observação
Normal	$x_a = (B^{-1} + H^T R^{-1} H)^{-1} (B^{-1} x_b + H^T R^{-1} y)$	Operações no espaço de estado
Ganho (prática)	$x_a = x_b + B H^T (H B H^T + R)^{-1} (y - H x_b)$	Operações no espaço de observação, mais eficiente

Ambas são matematicamente equivalentes — o **script simbólico** confirma a identidade e o **exemplo numérico** mostra que, mesmo com arredondamento, as duas produzem o mesmo resultado.



Vamos usar números concretos (dimensões pequenas) e calcular x_a pelas **duas fórmulas**.

Modelo físico: advecção–difusão 1D

A equação governante é:

$$\frac{\partial T}{\partial t} + u \frac{\partial T}{\partial x} = K \frac{\partial^2 T}{\partial x^2}$$

onde:

- $T(x, t)$ é a temperatura,
- u é a velocidade de advecção,
- K é o coeficiente de difusão.

Esquema numérico (diferenças finitas explícitas)

Usamos discretização de primeira ordem no tempo e segunda ordem no espaço:

$$T_i^{n+1} = T_i^n - \frac{u\Delta t}{2\Delta x} (T_{i+1}^n - T_{i-1}^n) + \frac{K\Delta t}{(\Delta x)^2} (T_{i+1}^n - 2T_i^n + T_{i-1}^n)$$



Vamos usar números concretos (dimensões pequenas) e calcular x_a pelas **duas fórmulas**.

Observações e assimilação 3D-Var

Vamos supor:

$$J(x) = (x - x_b)^T B^{-1} (x - x_b) + (y - Hx)^T R^{-1} (y - Hx)$$

- O modelo fornece o campo de fundo $x_b = T^b$,
- Temos observações esparsas de temperatura y ,
- O operador de observação H extrai os pontos observados,
- O 3D-Var minimiza

A solução analítica é:

$$x_a = x_b + BH^T (HBH^T + R)^{-1} (y - Hx_b)$$



```
program advec_diff_3dvar
implicit none
integer, parameter :: nx = 50, nt = 50
real(8), parameter :: L = 1.0d0, dt = 0.001d0, u = 1.0d0, K = 0.01d0
real(8) :: dx, t
real(8), dimension(nx) :: T, Tnew, Tb, Ta, y, diff
real(8), dimension(nx,nx) :: B, Ht, H, R, I, tmp, gain
integer :: i, n
```

```
dx = L / (nx-1)
```

```
! --- Condição inicial (gaussiana) ---
```

```
do i = 1, nx
  T(i) = exp(-((i*dx - 0.5d0)**2)/0.01d0)
end do
Tb = T
```

```
! --- Matriz de covariância B (identidade simplificada) ---
```

```
B = 0.0d0
do i = 1, nx
  B(i,i) = 0.05d0
end do
```

```
! --- Matriz de erro de observação R ---
```

```
R = 0.0d0
R(1,1) = 0.02d0
```

```
! --- Operador de observação H (observa apenas 1 ponto central) ---
```

```
H = 0.0d0
H(1, nx/2) = 1.0d0
Ht = transpose(H)
```

```
! --- Simulação do modelo (background) ---
```

```
do n = 1, nt
  call advec_diff_step(T, Tnew, u, K, dx, dt, nx)
  T = Tnew
end do
Tb = T ! estado background
```

```
! --- Observação sintética ---
```

```
y = 0.0d0
y(1) = Tb(nx/2) + 0.1d0 ! adiciona erro positivo
```

```
! --- Aplicação do 3DVar ---
```

```
tmp = matmul(H, matmul(B, Ht)) + R
gain = matmul(B, matmul(Ht, inv1x1(tmp))) ! ganho de Kalman
Ta = Tb + matmul(gain, (y - matmul(H, Tb)))
```

```
! --- Resultado ---
```

```
print *, "Ponto observado:", nx/2
print *, "Background:", Tb(nx/2)
print *, "Observação:", y(1)
print *, "Análise:", Ta(nx/2)
```

```
contains
```

```
subroutine advec_diff_step(T, Tnew, u, K, dx, dt, nx)
```

```
implicit none
integer, intent(in) :: nx
real(8), intent(in) :: u, K, dx, dt
real(8), dimension(nx), intent(in) :: T
real(8), dimension(nx), intent(out) :: Tnew
integer :: i
Tnew = T
do i = 2, nx-1
  Tnew(i) = T(i) - (u*dt/(2.d0*dx))*(T(i+1)-T(i-1)) + (K*dt/(dx*dx))*(T(i+1)-2*T(i)+T(i-1))
end do
! Condições de contorno periódicas
Tnew(1) = T(nx-1)
Tnew(nx) = T(2)
end subroutine advec_diff_step
```

```
function inv1x1(a) result(ainv)
real(8), dimension(1,1), intent(in) :: a
real(8), dimension(1,1) :: ainv
ainv(1,1) = 1.d0 / a(1,1)
end function inv1x1
```

```
end program advec_diff_3dvar
```



Como esse programa funciona:

- 1.Modelo físico:** propaga uma distribuição de temperatura gaussiana com advecção e difusão;
- 2.Observação:** coleta um único ponto (no centro da malha) com erro;
- 3.3DVar:** ajusta o campo de temperatura usando a observação — suavemente, devido à covariância B ;
- 4.Saída:** mostra o valor antes, observado e analisado.



Expansão para 4D-Var

No **4D-Var**, o custo considera a evolução temporal:

$$J(x_0) = (x_0 - x_b)^T B^{-1} (x_0 - x_b) + \sum_k \left(y_k - H M_{0,k}(x_0) \right)^T (R_k)^{-1} (y_k - H M_{0,k}(x_0))$$

onde $M_{0,k}$ é o modelo propagador.

A implementação requer **integração direta e adjunta** (ou iteração no tempo para minimizar J), o que pode ser feito com um gradiente descendente.

O programa em **Fortran completo do 4D-Var** para o mesmo modelo advecção–difusão (usando um esquema iterativo para minimizar J)



Expansão para 4D-Var

No **4D-Var**, o custo considera a evolução temporal:

$$J(x_0) = (x_0 - x_b)^T B^{-1} (x_0 - x_b) + \sum_k \left(y_k - HM_{0,k}(x_0) \right)^T (R_k)^{-1} (y_k - HM_{0,k}(x_0))$$

Descrição resumida do que o programa faz:

- monta o operador linear do modelo A (passo explícito advecção+difusão);
- gera uma "**verdade**" (trajetória) y_k a partir de uma condição inicial (duas gaussianas);
- gera **observações ruidosas** (H seleciona pontos);
- divide o período total em **janelas de assimilação** de comprimento win ;
- para cada janela resolve **as equações normais do 4D-Var** na variável inicial x_0 da janela:



Expansão para 4D-Var

No **4D-Var**, o custo considera a evolução temporal:

$$J(x_0) = (x_0 - x_b)^T B^{-1} (x_0 - x_b) + \sum_k \left(y_k - H M_{0,k}(x_0) \right)^T (R_k)^{-1} (y_k - H M_{0,k}(x_0))$$

$$\left(B^{-1} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} H A^k \right) x_0 = B^{-1} x_{b0} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} y_k$$

- usando **Gradiente Conjugado (CG)** para evitar inversões diretas;
- propaga a solução ótima x_0 pelo modelo na janela e grava a trajetória analisada;
- salva arquivos de saída para visualização



O código tem comentários explicativos e é dimensionado para que você possa alterar `nx`, `nt`, `win`, `Ne`, etc.

Salve como `advec_diff_4dvar.f90` e compile:

```
gfortran -O2 advec_diff_4dvar.f90 -o advec_diff_4dvar
./advec_diff_4dvar
```

Após rodar, os arquivos gerados serão:

- `4dvar_out.dat` — cada linha: tempo, verdade (`nx` valores), background (`nx`), análise (`nx`)
- `rmse_4dvar.dat` — colunas: tempo, `rmse_background`, `rmse_analysis`



Expansão para 4D-Var

$$J(x_0) = (x_0 - x_b)^T B^{-1} (x_0 - x_b) + \sum_k \left(y_k - H M_{0,k}(x_0) \right)^T (R_k)^{-1} (y_k - H M_{0,k}(x_0))$$



```
! advec_diff_4dvar.f90
program advec_diff_4dvar
  implicit none
  integer, parameter :: dp = selected_real_kind(15,307)
  integer, parameter :: nx = 60      ! grid points
  integer, parameter :: nt = 120     ! total time steps
  integer, parameter :: win = 12     ! window length (steps)
  real(dp), parameter :: L = 1.0_dp
  real(dp), parameter :: u = 1.0_dp
  real(dp), parameter :: kappa = 0.01_dp
  real(dp), parameter :: dx = L / real(nx-1, dp)
  real(dp), parameter :: dt = 0.25_dp * dx ! choose stable dt
  real(dp), parameter :: sigma_b = 0.10_dp
  real(dp), parameter :: sigma_obs = 0.02_dp

  ! Observations: indices where observations exist (m per time)
  integer, parameter :: m = 6
  integer, parameter :: obs_idx(m) = (/ 6, 14, 22, 30, 38, 46 /)

  ! arrays
  real(dp), allocatable :: A(:,,:), Ap(:,,:), AT(:,,:), ATp(:,,:)
  real(dp), allocatable :: truth(:,,:), bkg(:,,:), analysis(:,,:)
  real(dp), allocatable :: x0_true(:,), x0_b(:,)
  real(dp), allocatable :: y(:,)
  real(dp), allocatable :: B(:,,:), Binv(:,,:), R(:,,:), Rinv(:,,:)
  real(dp), allocatable :: H(:,,:), Ht(:,)

  ! temp / CG matrices
  real(dp), allocatable :: LHS(:,,:), RHS(:,), x0_opt(:,)

  integer :: i,j,k,t,win_k,info
  integer :: outunit, rmseunit
  real(dp) :: t0

  call seed_rng(123456)
```

$$\left(B^{-1} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} H A^k \right) x_0 = B^{-1} x_{b0} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} y_k$$



Expansão para 4D-Var



$$J(x_0) = (x_0 - x_b)^T B^{-1} (x_0 - x_b) + \sum_k \left(y_k - H M_{0,k}(x_0) \right)^T (R_k)^{-1} (y_k - H M_{0,k}(x_0))$$

```
! allocate
allocate(A(nx,nx), AT(nx,nx))
allocate(Ap(nx,nx,win+1), ATp(nx,nx,win+1))
allocate(truth(nt+1,nx), bkg(nt+1,nx), analysis(nt+1,nx))
allocate(x0_true(nx), x0_b(nx))
allocate(y(nt,m))
allocate(B(nx,nx), Binv(nx,nx), R(m,m), Rinv(m,m))
allocate(H(m,nx), Ht(nx,m))
allocate(LHS(nx,nx), RHS(nx), x0_opt(nx))
```

! build A

```
call build_A(A, nx, dx, dt, u, kappa)
AT = transpose(A)
```

! build powers A^k and (A^T)^k

```
Ap(:, :, 1) = identity(nx)
ATp(:, :, 1) = identity(nx)
do k = 2, win+1
  Ap(:, :, k) = matmul(A, Ap(:, :, k-1))
  ATp(:, :, k) = transpose(Ap(:, :, k))
end do
```

! truth initial condition (two gaussian bumps)

```
call make_truth_ic(nx, dx, x0_true)
truth(1, :) = x0_true
do t = 1, nt
  truth(t+1, :) = matmul(A, truth(t, :))
end do
```

! observations (one per time step at obs indices)

```
do t = 1, nt
  do i = 1, m
    y(t, i) = truth(t+1, obs_idx(i)) + sigma_obs * randn()
  end do
end do
```

$$\left(B^{-1} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} H A^k \right) x_0 = B^{-1} x_{b0} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} y_k$$



Expansão para 4D-Var



$$J(x_0) = (x_0 - x_b)^T B^{-1} (x_0 - x_b) + \sum_k \left(y_k - H M_{0,k}(x_0) \right)^T (R_k)^{-1} (y_k - H M_{0,k}(x_0))$$

! background: perturb initial truth and propagate free

```
x0_b = x0_true + sigma_b * randn_vec(nx)
bkg(1,:) = x0_b
do t = 1, nt
  bkg(t+1,:) = matmul(A, bkg(t,:))
end do
```

! build B (diagonal) and Bin

```
B = 0.0_dp
do i = 1, nx
  B(i,i) = sigma_b**2
  Bin(i,i) = 1.0_dp / B(i,i)
end do
```

! build R and Rinv (m x m)

```
R = 0.0_dp
do i = 1, m
  R(i,i) = sigma_obs**2
  Rinv(i,i) = 1.0_dp / R(i,i)
end do
```

! build H (m x nx) and Ht (nx x m)

```
H = 0.0_dp
do i = 1, m
  H(i, obs_idx(i)) = 1.0_dp
end do
Ht = transpose(H)
```

! open output files

```
open(newunit=outunit, file="4dvar_out.dat", status="replace", action="write")
write(outunit, '(A)') '# t truth(...) background(...) analysis(...)'
open(newunit=rmseunit, file="rmse_4dvar.dat", status="replace", action="write")
write(rmseunit, '(A)') '# t rmse_background rmse_analysis'
```

$$\left(B^{-1} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} H A^k \right) x_0 = B^{-1} x_{b0} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} y_k$$



Expansão para 4D-Var

$$J(x_0) = (x_0 - x_b)^T B^{-1} (x_0 - x_b) + \sum_k \left(y_k - H M_{0,k}(x_0) \right)^T (R_k)^{-1} (y_k - H M_{0,k}(x_0))$$



! initialize analysis with background initial guess

analysis(1,:) = bkg(1,:)

t = 1

do while (t <= nt)

! Determine window end

win_k = min(win, nt - t + 1)

! Build LHS and RHS for window starting at time t

! LHS = Binv + sum_{k=1..win_k} A^T k * H^T * Rinv * H * A^k

LHS = Binv

do k = 1, win_k

LHS = LHS + matmul(ATp(:, :, k+1), matmul(matmul(Ht, Rinv), matmul(H, Ap(:, :, k+1)))))

end do

! RHS = Binv * xb0 + sum_k A^T k * H^T * Rinv * y_k

RHS = 0.0_dp

RHS = matmul(Binv, bkg(t,:)) ! xb0 = background at window start

do k = 1, win_k

RHS = RHS + matmul(ATp(:, :, k+1), matmul(Ht, matmul(Rinv, y(t + k - 1, :)))))

end do

! Solve LHS * x0_opt = RHS using CG (x0 initial guess = xb0)

x0_opt = bkg(t,:) ! initial guess

call cg_solve(LHS, RHS, x0_opt, 1000, 1.0e-9_dp)

! propagate optimal x0 through the window and store analysis

do k = 0, win_k-1

analysis(t + k, :) = matmul(Ap(:, :, k+1), x0_opt)

end do

! also write the last time of window

analysis(t + win_k, :) = matmul(Ap(:, :, win_k+1), x0_opt)

! advance by window length (no overlap here, could do overlap if desired)

t = t + win_k

end do

$$\left(B^{-1} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} H A^k \right) x_0 = B^{-1} x_{b0} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} y_k$$



$$J(x_0) = (x_0 - x_b)^T B^{-1} (x_0 - x_b) + \sum_k \left(y_k - H M_{0,k}(x_0) \right)^T (R_k)^{-1} (y_k - H M_{0,k}(x_0))$$



! compute rmse per time and write outputs

do t = 1, nt+1

write(outunit, '(I6,1X,60F12.6,1X,60F12.6,1X,60F12.6)') t-1, truth(t,:), bkg(t,:), analysis(t,:)

write(rmseunit, '(I6,2F12.6)') t-1, rmse_vec(bkg(t,:), truth(t,:)), rmse_vec(analysis(t,:), truth(t,:))
end do

close(outunit)

close(rmseunit)

print *, '4D-Var run finished. Output: 4dvar_out.dat, rmse_4dvar.dat'

contains

!=====

subroutine build_A(A, nx, dx, dt, u, kappa)

integer, intent(in) :: nx

real(dp), intent(in) :: dx, dt, u, kappa

real(dp), intent(out) :: A(nx,nx)

integer :: i

A = 0.0_dp

A(1,1) = 1.0_dp

A(nx,nx) = 1.0_dp

do i = 2, nx-1

A(i,i-1) = u * dt / dx + kappa * dt / (dx*dx)

A(i,i) = 1.0_dp - u * dt / dx - 2.0_dp * kappa * dt / (dx*dx)

A(i,i+1) = kappa * dt / (dx*dx)

end do

end subroutine build_A

$$\left(B^{-1} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} H A^k \right) x_0 = B^{-1} x_{b0} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} y_k$$



$$J(x_0) = (x_0 - x_b)^T B^{-1} (x_0 - x_b) + \sum_k \left(y_k - HM_{0,k}(x_0) \right)^T (R_k)^{-1} (y_k - HM_{0,k}(x_0))$$



```
subroutine make_truth_ic(nx, dx, x0)
```

```
  integer, intent(in) :: nx
```

```
  real(dp), intent(in) :: dx
```

```
  real(dp), intent(out) :: x0(nx)
```

```
  integer :: i
```

```
  do i = 1, nx
```

```
    x0(i) = exp( - (( real(i-1,dp)*dx) - 0.25_dp )**2) / (2.0_dp*(0.05_dp**2)) ) + &  
            0.5_dp * exp( - (( real(i-1,dp)*dx) - 0.65_dp )**2) / (2.0_dp*(0.08_dp**2)) )
```

```
  end do
```

```
end subroutine make_truth_ic
```

```
!=====
```

```
function identity(n) result(l)
```

```
  integer, intent(in) :: n
```

```
  real(dp) :: l(n,n)
```

```
  integer :: i
```

```
  l = 0.0_dp
```

```
  do i = 1, n
```

```
    l(i,i) = 1.0_dp
```

```
  end do
```

```
end function identity
```

```
!=====
```

```
function randn() result(r)
```

```
  real(dp) :: r
```

```
  real(dp) :: u1,u2
```

```
  call random_number(u1); call random_number(u2)
```

```
  if (u1 < 1.0e-12_dp) u1 = 1.0e-12_dp
```

```
  r = sqrt(-2.0_dp*log(u1)) * cos(2.0_dp*acos(-1.0_dp)*u2)
```

```
end function randn
```

$$\left(B^{-1} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} H A^k \right) x_0 = B^{-1} x_{b0} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} y_k$$



$$J(x_0) = (x_0 - x_b)^T B^{-1} (x_0 - x_b) + \sum_k \left(y_k - HM_{0,k}(x_0) \right)^T (R_k)^{-1} (y_k - HM_{0,k}(x_0))$$

```
!=====
function randn_vec(n) result(v)
  integer, intent(in) :: n
  real(dp) :: v(n)
  integer :: i
  do i = 1, n
    v(i) = randn()
  end do
end function randn_vec
```

$$\left(B^{-1} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} H A^k \right) x_0 = B^{-1} x_{b0} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} y_k$$

```
!=====
subroutine cg_solve(A, b, x, maxit, tol)
  ! Conjugate Gradients for symmetric positive-definite A
  real(dp), intent(in) :: A(:, :), b(:)
  real(dp), intent(inout) :: x(:)
  integer, intent(in) :: maxit
  real(dp), intent(in) :: tol
  integer :: n, i, it
  real(dp), allocatable :: r(:), p(:), Ap(:)
  real(dp) :: alpha, beta, rsold, rsnew, pAp

  n = size(b)
  allocate(r(n), p(n), Ap(n))
  r = b - matmul(A, x)
  p = r
  rsold = dot_product(r, r)
  do it = 1, maxit
    Ap = matmul(A, p)
    pAp = dot_product(p, Ap)
    if (abs(pAp) < 1.0e-30_dp) exit
    alpha = rsold / pAp
    x = x + alpha * p
    r = r - alpha * Ap
    rsnew = dot_product(r, r)
    if (sqrt(rsnew) < tol) exit
    beta = rsnew / rsold
    p = r + beta * p
    rsold = rsnew
  end do
  deallocate(r, p, Ap)
end subroutine cg_solve
```



$$J(x_0) = (x_0 - x_b)^T B^{-1} (x_0 - x_b) + \sum_k \left(y_k - HM_{0,k}(x_0) \right)^T (R_k)^{-1} (y_k - HM_{0,k}(x_0))$$



!=====

```
function rmse_vec(a, b) result(rmse)
  real(dp), intent(in) :: a(:), b(:)
  real(dp) :: rmse
  integer :: n
  n = size(a)
  rmse = sqrt(sum((a - b)**2) / real(n, dp))
end function rmse_vec

end program advec_diff_4dvar
```

$$\left(B^{-1} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} H A^k \right) x_0 = B^{-1} x_{b0} + \sum_{k=1}^{win} A^{Tk} H^T R^{-1} y_k$$



$$J(x_0) = (x_0 - x_b)^T B^{-1} (x_0 - x_b) + \sum_k \left(y_k - HM_{0,k}(x_0) \right)^T (R_k)^{-1} (y_k - HM_{0,k}(x_0))$$



Observações finais e sugestões

- O programa usa um **LHS explicitamente montado** (matriz densa $n_x \times n_x$). Para n_x grande, troque a montagem por um operador que aplique LHS a um vetor (matvec) sem formar LHS inteiro — isso permite CG escalável.
- H está implementado como seleção de índices (m pontos). Para observações esparsas no tempo, adapte $y(t, :)$ adequadamente.
- A janela aqui é não-sobreposta (stride = win). Você pode escolher overlap para suavizar trocas entre janelas.
- Para **4D-Var não-lineal**, a técnica requer um modelo adjunto para calcular gradiente; aqui usamos a vantagem do **modelo linear** (A) para montar a normal diretamente.
- Se preferir, eu adapto o código para:
 - aplicar **precondicionador** em CG (usando aproximador diagonal de LHS),
 - trabalhar com B não-diagonal (ex.: exponencial),
 - variar janela e stride, ou
 - gerar visualizações em Python automaticamente.



$$J(x_0) = (x_0 - x_b)^T B^{-1} (x_0 - x_b) + \sum_k \left(y_k - HM_{0,k}(x_0) \right)^T (R_k)^{-1} (y_k - HM_{0,k}(x_0))$$



1) Kalman Filter (KF) — `kf_advec_diff.f90`

- Modelo linear: $x_{k+1} = Ax_k$, observação $y_k = Hx_k + \varepsilon$.
- KF recursivo (previsão + atualização):
 - previsão: $x^f = Ax_{k-1}^a$, $P^f = AP_{k-1}^a A^T + Q$
 - atualização: $K = P^f H^T (HP^f H^T + R)^{-1}$; $x^a = x^f + K(y - Hx^f)$; $P^a = (I - KH)P^f$
- Permite B (initial P_0^a (não-diagonal (ex.: exponencial) e modelo Q diagonal pequena.
- Salva arquivo `kf_out.dat` com cada linha: time, truth(nx), forecast(nx), analysis(nx).
- Cálculo de RMSE salvo em `kf_rmse.dat`.



$$J(x_0) = (x_0 - x_b)^T B^{-1} (x_0 - x_b) + \sum_k \left(y_k - HM_{0,k}(x_0) \right)^T (R_k)^{-1} (y_k - HM_{0,k}(x_0))$$



2) Ensemble Kalman Filter (EnKF) — `enkf_advvec_diff.f90`

- EnKF estocástico (perturbed obs).
- Options:
 - `Ne` ensemble size,
 - `localize = .true.` to apply Gaspari–Cohn localization on sample covariance before computing gain,
 - `inflation` multiplicative factor >1.0 to counter undersampling.
- Implements localization by multiplying sample covariance entries by localization matrix `rho(i,j)` computed from grid distances and Gaspari–Cohn function.
- Saves `enkf_out.dat` and `enkf_rmse.dat`.



Módulo 2 — Formulação Matemática

Exemplo Prático: Assimilação de Dados com 3D-Var

Vamos realizar um exemplo simples usando a **fórmula de análise do 3D-Var** em Python. O objetivo é ajustar um vetor de temperatura do modelo com base em uma observação.

Exemplo de Dados:

Suponha que temos um vetor de temperatura do modelo e uma observação em um ponto específico. Vamos usar a fórmula do 3D-Var para ajustar o modelo.



Módulo 2 — Formulação Matemática

```
import numpy as np

# Dados do modelo (temperatura estimada)
x_b = np.array([10, 12, 14, 16, 18, 20]) # Temperatura no modelo

# Observação
y = np.array([15.5]) # Observação de temperatura

# Matriz de covariância do erro de modelo (B)
B = np.array([[1]])

# Matriz de covariância do erro de observação (R)
R = np.array([[0.5]])

# Operador de observação (H) - no caso, uma observação no ponto 2
H = np.array([[0, 0, 1, 0, 0, 0]])

# Cálculo da análise
Ht = H.T
B_inv = np.linalg.inv(B)
R_inv = np.linalg.inv(R)

# Fórmula da análise (ajuste do modelo)
x_hat = x_b + B_inv @ Ht @ np.linalg.inv(H @ B_inv @ Ht + R_inv) @ (y - H @ x_b)

print("Estado corrigido após assimilação:", x_hat)
```

Exercício 2:

1. Implemente o processo de assimilação utilizando a fórmula do **3D-Var** para um modelo simples de temperatura.

1. Varie os valores das matrizes de covariância **B** e **R** e observe como a análise $x \sim$ muda.

2. Tente aplicar esse processo para diferentes pontos de observação.



Conclusão do Módulo 2

- A formulação matemática da assimilação de dados envolve a definição de um vetor de estado e a relação com as observações, considerando os erros de modelo e de observação.
- A função custo é central para os métodos de assimilação, como o **3D-Var**, onde buscamos minimizar a discrepância entre o modelo e as observações.
- Com a fórmula de análise, podemos ajustar o estado do modelo com base nas observações e suas incertezas.